# 第二节——HiveSQL基础技能2

## 课堂目标

1、掌握inner join

2、掌握left join

3、掌握full join和union all

4、掌握各种连接的组合

## 表连接

## 【inner join】（25min）

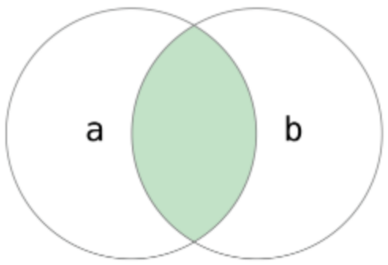

内连接：返回两个表的交集

### 举例说明：

表1：user_list_1

| user_id | user_name |
|---|---|
| 10001 | Abby |
| 10002 | Ailsa |
| 10003 | Alice |
| 10004 | Alina |
| 10005 | Allison |
| 10006 | Angelia |

表2：user_list_2

| user_id | user_name |
|---|---|
| 10001 | Abby |
| 10003 | Alice |
| 10004 | Alina |
| 10007 | Amanda |
| 10008 | Anne |
| 10009 | Ann |

找出既在**user_list_1**也在**user_list_2**的用户：

```sql
--既在user_list_1也在user_list_2的用户--
SELECT *
FROM user_list_1 a JOIN user_list_2 b ON a.user_id=b.user_id;
```

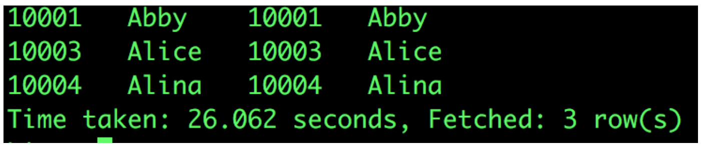

```
10001   Abby    10001   Abby
10003   Alice   10003   Alice
10004   Alina   10004   Alina
Time taken: 26.062 seconds, Fetched: 3 row(s)
```

注意：

- 表连接时，必须进行重命名
- on后面使用的连接条件必须起到唯一键值的作用
- inner可省略不写，效果一样

练习：

| **user_trade**列名 | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **piece** | 购买数量 |
| **price** | 价格 |
| **pay_amount** | 支付金额 |
| **goods_category** | food, clothes, book, computer, electronics, shoes |
| **pay_time** | 1323308943，时间戳 |
| **dt** | partition，‘yyyy-mm-dd’ |

| **user_refund**列名 | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **refund_piece** | 退款件数 |
| **refund_amount** | 退款金额 |
| **refund_time** | 1323308943，时间戳 |
| **dt** | partition，‘yyyy-mm-dd’ |

**1、在2019年购买后又退款的用户：**

```sql
--在2019年购买后又退款的用户--
SELECT a.user_name
FROM
        (SELECT distinct user_name
        FROM user_trade
        WHERE year(dt)=2019)a
    JOIN
        (SELECT distinct user_name
        FROM user_refund
        WHERE year(dt)=2019)b on a.user_name=b.user_name;
```

常见错误：没有写别名

```sql
SELECT user_name
FROM
        (SELECT distinct user_name
        FROM user_trade
        WHERE year(dt)=2019)a
    JOIN
        (SELECT distinct user_name
        FROM user_refund
        WHERE year(dt)=2019)b on a.user_name=b.user_name;
```

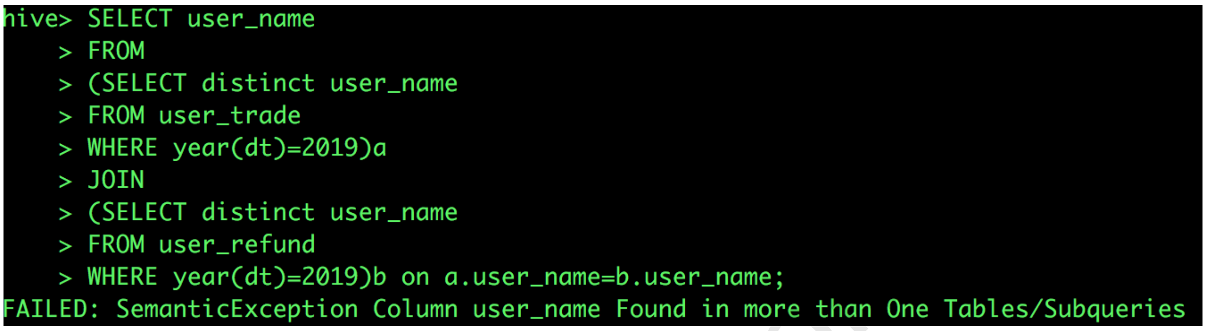

```
hive> SELECT user_name
    > FROM
    > (SELECT distinct user_name
    > FROM user_trade
    > WHERE year(dt)=2019)a
    > JOIN
    > (SELECT distinct user_name
    > FROM user_refund
    > WHERE year(dt)=2019)b on a.user_name=b.user_name;
FAILED: SemanticException Column user_name Found in more than One Tables/Subqueries
```

如果不进行去重的话，会怎么样?

```sql
SELECT count(a.user_name),
       count(distinct a.user_name)
FROM
        (SELECT user_name
        FROM user_trade
        WHERE year(dt)=2019)a
    JOIN
        (SELECT user_name
        FROM user_refund
        WHERE year(dt)=2019)b on a.user_name=b.user_name;
```

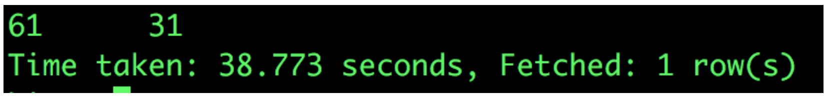

```
61      31
Time taken: 38.773 seconds, Fetched: 1 row(s)
```

！！注意：一定要先去重，再做表连接，养成良好习惯

PS：虽然可以先连接后再去重，但是这么做的话，执行效率会低。

## 2、在2017年和2018年都购买的用户：

```
--在2017年和2018年都购买的用户--
SELECT a.user_name
FROM
      (SELECT distinct user_name
      FROM user_trade
      WHERE year(dt)=2017)a
    JOIN
      (SELECT distinct user_name
      FROM user_trade
      WHERE year(dt)=2018)b on a.user_name=b.user_name;
```

| trade_2017&2018&2019列名 | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **amount** | 金额 |
| **trade_time** | 交易时间，2017-02-05 06:31:50 |

## 3、在2017年、2018年、2019都有交易的用户：

```sql
--在2017年、2018年、2019都有交易的用户--
##第一种写法
SELECT distinct a.user_name
FROM trade_2017 a
JOIN trade_2018 b on a.user_name=b.user_name
JOIN trade_2019 c on b.user_name=c.user_name;

##第二种写法
SELECT a.user_name
FROM
      (SELECT distinct user_name
      FROM trade_2017)a
    JOIN
      (SELECT distinct user_name
      FROM trade_2018)b on a.user_name=b.user_name
    JOIN
      (SELECT distinct user_name
      FROM trade_2019)c on b.user_name=c.user_name;
```

- 在表的数据量级很大时，推荐第二种写法
- 为什么写a.user_name呢？b.user_name或者c.user_name可以吗？——当然可以。

因为JOIN是取表的交集，所以不管取哪个表的这个字段都是一样的结果。

初学者常犯错误写法：

```sql
----错误写法----
SELECT distinct a.user_name
FROM trade_2017 a
JOIN trade_2018 b
JOIN trade_2019 c on a.user_name=b.user_name=c.user_name;
```

## 【left join】（25min）

首先，我们先来看一下，对表1和表2进行左连接后，发生了什么。

```sql
SELECT *
FROM user_list_1 a LEFT JOIN user_list_2 b ON a.user_id=b.user_id;
```

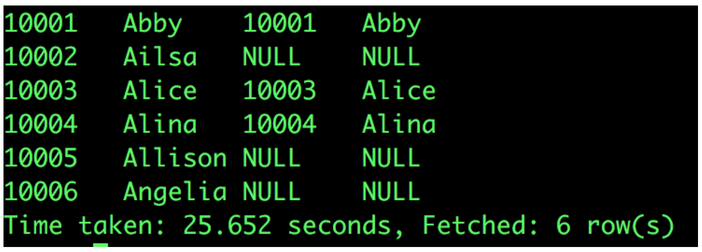

```
10001   Abby    10001   Abby
10002   Ailsa   NULL    NULL
10003   Alice   10003   Alice
10004   Alina   10004   Alina
10005   Allison NULL    NULL
10006   Angelia NULL    NULL
Time taken: 25.652 seconds, Fetched: 6 row(s)
```

进行左连接后，以左边的表1为全集，返回能够匹配上的右边表2的匹配结果，没有匹配上的则显示**NULL**。

拓展：

**right join**：以右边的表为全集，返回能够匹配上的左表的匹配结果，没有匹配上的则显示NULL

但其完全可以由left join改写出同样的结果，所以较少使用

**LEFT JOIN** 关键字从左表（**table1**）返回所有的行，即使右表（**table2**）中没有匹配。如果右表中没有匹配，则结果为 **NULL**。

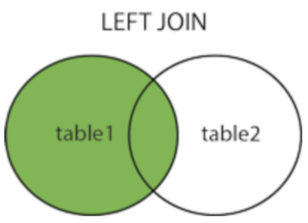

**RIGHT JOIN** 关键字从右表（**table2**）返回所有的行，即使左表（**table1**）中没有匹配。如果左表中没有匹配，则结果为 **NULL**。

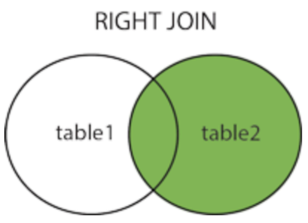

## 举例说明：

如何取出，在**user_list_1**表中但是不在**user_list_2**的用户？

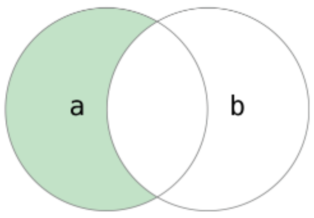

```sql
--在user_list_1表中但是不在user_list_2的用户--
SELECT a.user_id,
       a.user_name
FROM user_list_1 a LEFT JOIN user_list_2 b ON a.user_id=b.user_id
WHERE b.user_id is null;
```

练习：

## 1、在2019年购买，但是没有退款的用户：

```
--在2019年购买，但是没有退款的用户--
SELECT a.user_name
FROM
      (SELECT distinct user_name
      FROM user_trade
      WHERE year(dt)=2019)a
    LEFT JOIN
      (SELECT distinct user_name
      FROM user_refund
      WHERE year(dt)=2019)b on a.user_name=b.user_name
WHERE b.user_name is null;
```

## 2、在2019年购买用户的学历分布：

| user_info 列名 | 举例 |
|---|---|
| **user_id** | 10001,10002 |
| **user_name** | Amy, Dennis |
| **sex** | [male, female] |
| **age** | [13,70] |
| **city** | beijing, shanghai |
| **firstactivetime** | 2019-04-19 15:40:00 |
| **level** | [1,10] |
| **extra1** | string类型：{"systemtype":"ios","education":"master","marriage_status":"1","phonebrand":"iphone X"} |
| **extra2** | map<string,string>类型：{"systemtype":"ios","education":"master","marriage_status":"1","phonebrand":"iphone X"} |

```
--在2019年购买用户的学历分布--
SELECT b.education,
       count(a.user_name)
FROM
      (SELECT distinct user_name
      FROM user_trade
      WHERE year(dt)=2019)a
    LEFT JOIN
      (SELECT user_name,
              get_json_object(extra1, '$.education') as education
      FROM user_info)b on a.user_name=b.user_name
GROUP BY b.education;
```

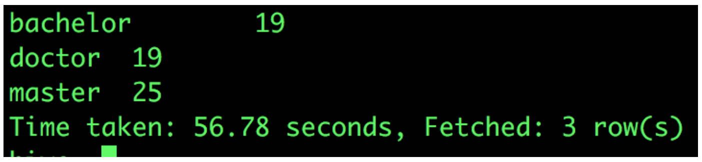

```
bachelor        19
doctor  19
master  25
Time taken: 56.78 seconds, Fetched: 3 row(s)
```

注意：get_json_object(extra1, '$.education')可以换成extra2['education']

### 3、在2017和2018年都购买，但是没有在2019年购买的用户：

| trade_2017&2018&2019列名 | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **amount** | 金额 |
| **trade_time** | 交易时间，2017-02-05 06:31:50 |

```sql
--在2017和2018年都购买，但是没有在2019年购买的用户--
SELECT a.user_name
FROM
      (SELECT distinct user_name
       FROM trade_2017)a
    JOIN
       (SELECT distinct user_name
       FROM trade_2018)b on a.user_name=b.user_name
    LEFT JOIN
       (SELECT distinct user_name
       FROM trade_2019)c on b.user_name=c.user_name
WHERE c.user_name is null;
```

- a.user_name换成b.user_name也可以

这种写法行不行？——可以的！

```sql
SELECT c.user_name
FROM
      (SELECT distinct a.user_name
      FROM trade_2017 a JOIN trade_2018 b on a.user_name=b.user_name)c
    LEFT JOIN
      (SELECT distinct user_name
      FROM trade_2019)d on c.user_name=d.user_name
WHERE d.user_name is null;
```

这种写法行不行？——可以，但不推荐！

```sql
SELECT distinct a.user_name
FROM trade_2017 a
JOIN trade_2018 b on a.user_name=b.user_name
LEFT JOIN trade_2019 c on b.user_name=c.user_name
WHERE c.user_name is null;
```

注意：如果表比较小的时候，这样写影响不大。但是有分区的大表，这样写执行速度很慢。

## 【full join】（10min）

### 举例说明：

首先，我们先来看一下，对表1和表2进行全连接后，发生了什么。

```sql
SELECT *
FROM user_list_1 a FULL JOIN user_list_2 b ON a.user_id=b.user_id;
```

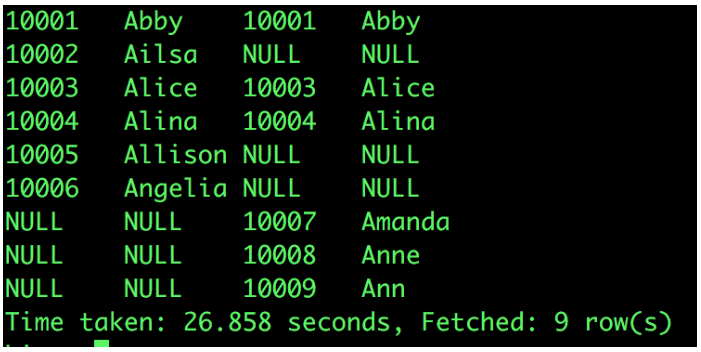

```
10001   Abby    10001   Abby
10002   Ailsa   NULL    NULL
10003   Alice   10003   Alice
10004   Alina   10004   Alina
10005   Allison NULL    NULL
10006   Angelia NULL    NULL
NULL    NULL    10007   Amanda
NULL    NULL    10008   Anne
NULL    NULL    10009   Ann
Time taken: 26.858 seconds, Fetched: 9 row(s)
```

**FULL OUTER JOIN** 关键字只要左表（**table1**）和右表（**table2**）其中一个表中存在匹配，则返回行。**FULL OUTER JOIN** 关键字结合了 **LEFT JOIN** 和 **RIGHT JOIN** 的结果。

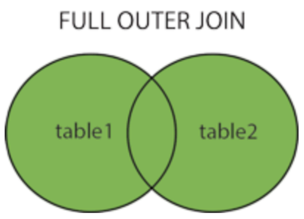

### 练习：

**1、user_list_1和user_list_2的所有用户：**

```sql
--user_list_1和user_list_2的所有用户--
SELECT coalesce(a.user_name,b.user_name)
FROM user_list_1 a FULL JOIN user_list_2 b on a.user_id=b.user_id;
```

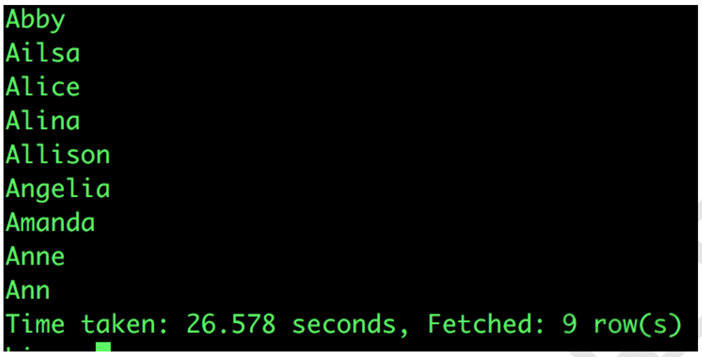

```
Abby
Ailsa
Alice
Alina
Allison
Angelia
Amanda
Anne
Ann
Time taken: 26.578 seconds, Fetched: 9 row(s)
```

拓展：coalesce是一个函数， (expression_1, expression_2, ...,expression_n)依次参考各参数表达式，遇到非null值即停止并返回该值。如果所有的表达式都是空值，最终将返回一个空值。

## 【union all】（20min）

表1：user_list_1

| user_id | user_name |
|---|---|
| 10001 | Abby |
| 10002 | Ailsa |
| 10003 | Alice |
| 10004 | Alina |
| 10005 | Allison |
| 10006 | Angelia |

表3：user_list_3

| user_id | user_name |
|---|---|
| 10290 | Michael |
| 10291 | Avery |
| 10292 | Reilly |
| 10293 | Dillon |
| 10294 | Walton |

**union all**：联合所有

## 举例说明：

将**user_list_1**和**user_list_3**合并在一起：

```sql
SELECT user_id,
       user_name
FROM user_list_1
UNION ALL
SELECT user_id,
       user_name
FROM user_list_3;
```

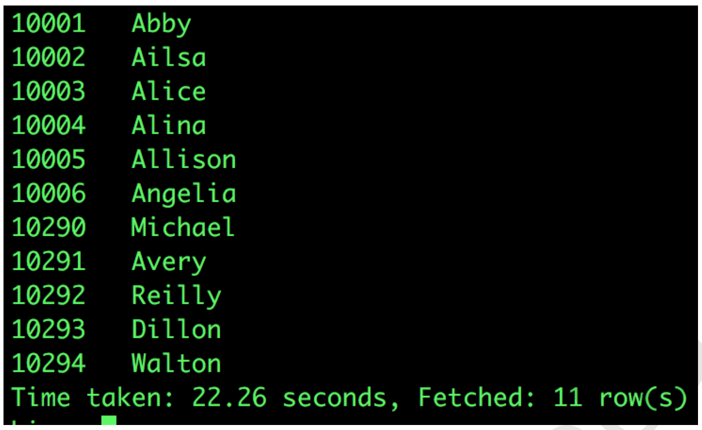

```
10001   Abby
10002   Ailsa
10003   Alice
10004   Alina
10005   Allison
10006   Angelia
10290   Michael
10291   Avery
10292   Reilly
10293   Dillon
10294   Walton
Time taken: 22.26 seconds, Fetched: 11 row(s)
```

注意：

- 字段名称必须一致
- 字段顺序必须一致
- 没有连接条件

```sql
----错误写法----
SELECT user_name,
       user_id
FROM user_list_1
UNION ALL
SELECT user_id,
       user_name
FROM user_list_3;
```

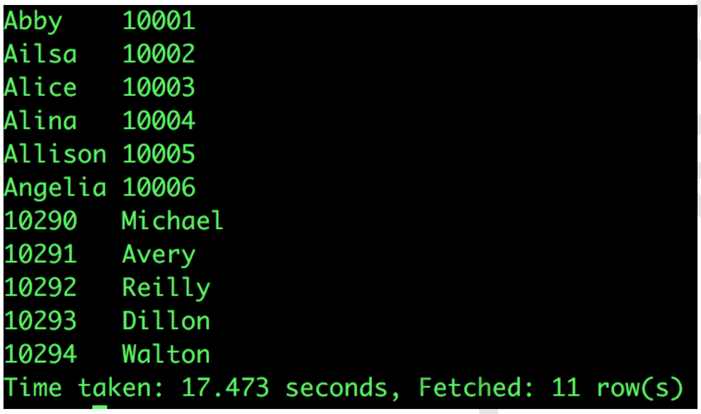

```
Abby    10001
Ailsa   10002
Alice   10003
Alina   10004
Allison 10005
Angelia 10006
10290   Michael
10291   Avery
10292   Reilly
10293   Dillon
10294   Walton
Time taken: 17.473 seconds, Fetched: 11 row(s)
```

练习:

**1、2017-2019年有交易的所有用户数:**

| **trade_2017&2018&2019**列名 | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **amount** | 金额 |
| **trade_time** | 交易时间，2017-02-05 06:31:50 |

```
--2017-2019年有交易的所有用户数--
##写法一
SELECT count(distinct a.user_name),
       count(a.user_name)
FROM
    (
      SELECT user_name
      FROM trade_2017
    UNION ALL
      SELECT user_name
      FROM trade_2018
    UNION ALL
      SELECT user_name
      FROM trade_2019)a;


##写法二
SELECT count(distinct a.user_name),
       count(a.user_name)
FROM
    (
      SELECT user_name
      FROM trade_2017
    UNION
      SELECT user_name
      FROM trade_2018
    UNION
      SELECT user_name
      FROM trade_2019)a;
```

- **UNION ALL和UNION的区别：**

| 对比 | **UNION ALL** | **UNION** |
|---|---|---|
| 对重复结果的处理 | 不会去除重复记录 | 在进行表连接后会筛选掉重复的记录 |
| 对排序的处理 | 只是简单的将两个结果合并后就返回 | 将会按照字段的顺序进行排序 |
| 效率 | 更快 | 更慢 |
| 总述 | 不去重不排序 | 去重且排序 |

PS：如果表很大时推荐先去重，再进行union all。

- 常见错误——没有对**union all**后的表进行重命名：

```
----错误写法----
SELECT count(distinct user_name)
FROM
    (
      SELECT user_name
      FROM trade_2017
    UNION ALL
      SELECT user_name
      FROM trade_2018
    UNION ALL
      SELECT user_name
      FROM trade_2019);
```

- 常见错误——直接对表进行**UNION ALL**：

```
----错误写法----
SELECT count(distinct user_name)
FROM trade_2017
UNION ALL trade_2018
UNION ALL trade_2019;
```

## 2、2019年每个用户的支付和退款金额汇总：

| **user_trade**列名 | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **piece** | 购买数量 |
| **price** | 价格 |
| **pay_amount** | 支付金额 |
| **goods_category** | food, clothes, book, computer, electronics, shoes |
| **pay_time** | 1323308943，时间戳 |
| **dt** | partition，'yyyy-mm-dd' |

| **user_refund列名** | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **refund_piece** | 退款件数 |
| **refund_amount** | 退款金额 |
| **refund_time** | 1323308943，时间戳 |
| **dt** | partition，‘yyyy-mm-dd’ |

```sql
--2019年每个用户的支付和退款金额汇总--
SELECT a.user_name,
       sum(a.pay_amount),
       sum(a.refund_amount)
FROM
    (
      SELECT user_name,
             sum(pay_amount) as pay_amount,
             0 as refund_amount
      FROM user_trade
      WHERE year(dt)=2019
      GROUP BY user_name
    UNION ALL
      SELECT user_name,
             0 as pay_amount,
             sum(refund_amount) as refund_amount
      FROM user_refund
      WHERE year(dt)=2019
      GROUP BY user_name
    )a
GROUP BY a.user_name;
```

- 如何用**full join**来实现该题目？

```sql
SELECT coalesce(a.user_name,b.user_name),
       a.pay_amount,
       b.refund_amount
FROM
     (SELECT user_name,
             sum(pay_amount) as pay_amount
      FROM user_trade
      WHERE year(dt)=2019
      GROUP BY user_name)a
    FULL JOIN
      (SELECT user_name,
             sum(refund_amount) as refund_amount
      FROM user_refund
      WHERE year(dt)=2019
      GROUP BY user_name)b on a.user_name=b.user_name;
```

与第一种写法有什么结果差异？——没有退款的人，退款金额显示NULL

**如果用第二种写法，如何把NULL都变成0呢？**

```sql
SELECT coalesce(a.user_name,b.user_name),
       if(a.pay_amount is null,0,a.pay_amount),
       if(b.refund_amount is null,0,b.refund_amount)
FROM
     (SELECT user_name,
             sum(pay_amount) as pay_amount
      FROM user_trade
      WHERE year(dt)=2019
      GROUP BY user_name)a
    FULL JOIN
      (SELECT user_name,
             sum(refund_amount) as refund_amount
      FROM user_refund
      WHERE year(dt)=2019
      GROUP BY user_name)b on a.user_name=b.user_name;
```

问题变形：**2019年每个支付用户的支付金额和退款金额**

```sql
SELECT a.user_name,
       a.pay_amount,
       b.refund_amount
FROM
     (SELECT user_name,
             sum(pay_amount) as pay_amount
      FROM user_trade
      WHERE year(dt)=2019
      GROUP BY user_name)a
    LEFT JOIN
      (SELECT user_name,
             sum(refund_amount) as refund_amount
      FROM user_refund
      WHERE year(dt)=2019
      GROUP BY user_name)b on a.user_name=b.user_name;
```

## 重点练习（20min）

**1、首次激活时间在2017年，但是一直没有支付的用户年龄段分布(使用user_trade和user_info两个表)**

| user_info 列名 | 举例 |
|---|---|
| **user_id** | 10001,10002 |
| **user_name** | Amy, Dennis |
| **sex** | [male, female] |
| **age** | [13,70] |
| **city** | beijing, shanghai |
| **firstactivetime** | 2019-04-19 15:40:00 |
| **level** | [1,10] |
| **extra1** | string类型：{"systemtype":"ios","education":"master","marriage_status":"1","phonebrand":"iphone X"} |
| **extra2** | map<string,string>类型：{"systemtype":"ios","education":"master","marriage_status":"1","phonebrand":"iphone X"} |

| user_trade列名 | 举例 |
|---|---|
| user_name | Amy, Dennis |
| piece | 购买数量 |
| price | 价格 |
| pay_amount | 支付金额 |
| goods_category | food, clothes, book, computer, electronics, shoes |
| pay_time | 1323308943，时间戳 |
| dt | partition，‘yyyy-mm-dd’ |

```sql
--首次激活时间在2017年，但是一直没有支付的用户年龄段分布--
SELECT a.age_level,
       count(a.user_name)
FROM
        (SELECT user_name,
                case when age<20 then '20岁以下'
                    when age>=20 and age<30 then '20-30岁'
                    when age>=30 and age<40 then '30-40岁'
                    else '40岁以上' end as age_level
        FROM user_info
        WHERE year(firstactivetime)=2019)a
      LEFT JOIN
        (SELECT distinct user_name
        FROM user_trade
        WHERE dt>0)b on a.user_name=b.user_name
WHERE b.user_name is null
GROUP BY a.age_level;
```

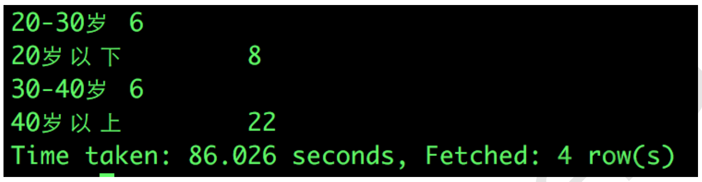

```
20-30岁	6
20岁以下	8
30-40岁	6
40岁以上	22
Time taken: 86.026 seconds, Fetched: 4 row(s)
```

常见错误——没有对子查询中的字段进行重命名：

```sql
----错误写法----
SELECT a.age,
       count(a.user_name)
FROM
        (SELECT user_name,
                case when age<20 then '20岁以下'
                    when age>=20 and age<30 then '20-30岁'
                    when age>=30 and age<40 then '30-40岁'
                    else '40岁以上' end
        FROM user_info
        WHERE year(firstactivetime)=2019)a
      LEFT JOIN
        (SELECT distinct user_name
        FROM user_trade
        WHERE dt>0)b on a.user_name=b.user_name
WHERE b.user_name is null
GROUP BY a.age;
```

**2、2018、2019年交易的用户，其激活时间段分布(使用trade_2018、trade_2019和user_info三个表)**

| trade_2017&2018&2019列名 | 举例 |
|---|---|
| **user_name** | Amy, Dennis |
| **amount** | 金额 |
| **trade_time** | 交易时间，2017-02-05 06:31:50 |

| user_info 列名 | 举例 |
|---|---|
| **user_id** | 10001,10002 |
| **user_name** | Amy, Dennis |
| **sex** | [male, female] |
| **age** | [13,70] |
| **city** | beijing, shanghai |
| **firstactivetime** | 2019-04-19 15:40:00 |
| **level** | [1,10] |
| **extra1** | string类型：{"systemtype":"ios","education":"master","marriage_status":"1","phonebrand":"iphone X"} |
| **extra2** | map<string,string>类型：{"systemtype":"ios","education":"master","marriage_status":"1","phonebrand":"iphone X"} |

```sql
--2018、2019年交易的用户，其激活时间段分布--
SELECT hour(firstactivetime),
        count(a.user_name)
FROM
      (
        SELECT user_name
        FROM trade_2018
      UNION
        SELECT user_name
        FROM trade_2019)a
      LEFT JOIN user_info b on a.user_name=b.user_name
GROUP BY hour(firstactivetime);
```

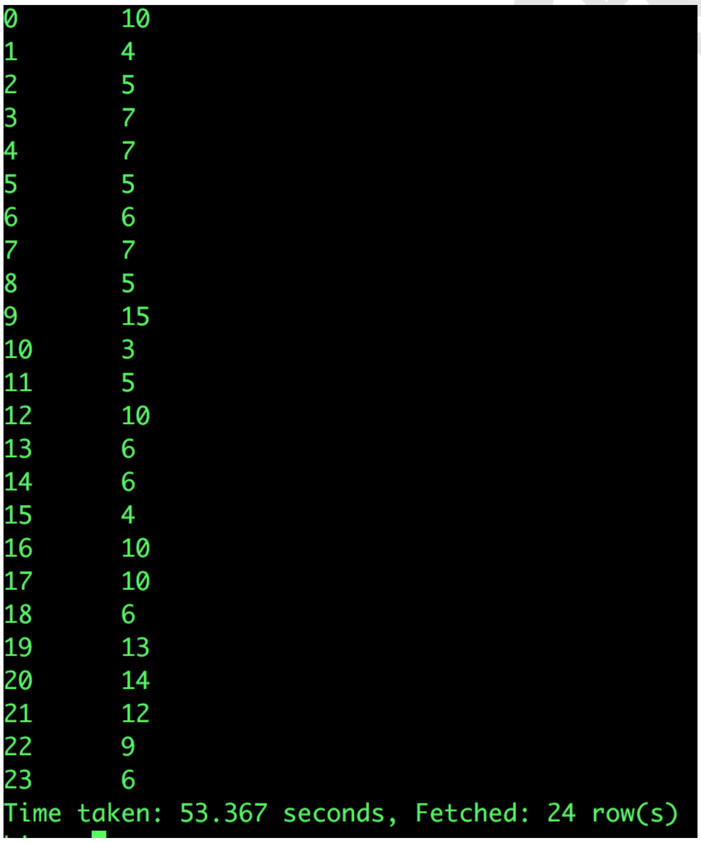

```
0       10
1       4
2       5
3       7
4       7
5       5
6       6
7       7
8       5
9       15
10      3
11      5
12      10
13      6
14      6
15      4
16      10
17      10
18      6
19      13
20      14
21      12
22      9
23      6
Time taken: 53.367 seconds, Fetched: 24 row(s)
```

## 总结

1. 在实际业务场景中，熟练选择JOIN、LEFT JOIN来解决具体问题
2. 区分好FULL JOIN和UNION ALL的使用场景
3. 在多表连接时，注意各种细节和业务逻辑
4. 避免常见错误

## 作业

作业1：在2019年购买后又退款的用户性别分布(使用user_trade、user_refund)

作业2：在2018年购买，但是没在2019年购买的用户城市城市分布(使用user_trade、user_refund)

作业3：2017-2019年，有交易但是没退款的用户的手机品牌分布(使用trade_2017、trade_2018、trade_2019、user_refund、user_info)